

MAT-269: Sesión 7

Estimación bajo restricciones sobre μ y Σ

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Suponga $\mathbf{x}_1, \dots, \mathbf{x}_n$ vectores aleatorios IID desde $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y considere:¹

1. $\boldsymbol{\mu} = \boldsymbol{\mu}_0$ conocido. Entonces,

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}_0)(\mathbf{x}_i - \boldsymbol{\mu}_0)^\top.$$

2. $\boldsymbol{\Sigma} = \boldsymbol{\Sigma}_0$ conocido. De este modo,

$$\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}.$$

3. $\boldsymbol{\mu} = \gamma \mathbf{a}$, $\gamma \in \mathbb{R}$ con $\mathbf{a} \in \mathbb{R}^p$ conocido. Luego,

$$\hat{\gamma}_{\boldsymbol{\Sigma}} = \frac{\mathbf{a}^\top \boldsymbol{\Sigma}^{-1} \bar{\mathbf{x}}}{\mathbf{a}^\top \boldsymbol{\Sigma}^{-1} \mathbf{a}}.$$

Para $\boldsymbol{\Sigma}$ desconocido, tenemos:

$$\hat{\gamma} = \frac{\mathbf{a}^\top \mathbf{S}^{-1} \bar{\mathbf{x}}}{\mathbf{a}^\top \mathbf{S}^{-1} \mathbf{a}}.$$

¹Ud. lo deberá resolver como parte de la Tarea 1 (Entrega: 4 Mayo).



4. $A\mu = a$, $A \in \mathbb{R}^{q \times p}$, $a \in \mathbb{R}^q$ matrices conocidas. Luego

$$\hat{\mu}_{\Sigma} = \bar{x} - \Sigma A^{\top} (A \Sigma A^{\top})^{-1} (A \bar{x} - a),$$

para Σ desconocido

$$\hat{\mu} = \bar{x} - S A^{\top} (A S A^{\top})^{-1} (A \bar{x} - a).$$

5. $\Sigma = \phi V$ con $V > 0$ conocida y $\phi > 0$. Por tanto,

$$\hat{\mu} = \bar{x}, \quad \hat{\phi} = \frac{1}{p} \text{tr}(V^{-1} S).$$



Matriz de covarianza diagonal

Suponga que

$$\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}, \quad \text{con} \quad \Sigma_{12} = \mathbf{0} = \Sigma_{21}^\top,$$

y $\mu = (\mu_1^\top, \mu_2^\top)^\top$. De este modo, tenemos $\theta = (\mu_1, \mu_2, \Sigma_{11}, \Sigma_{22})$, así la función de log-verosimilitud adopta la forma:

$$\ell(\theta) = -\frac{np}{2} \log 2\pi - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu).$$

Note que el estimador ML para μ no depende de Σ , luego $\hat{\mu} = \bar{x}$. Ahora, usando que

$$|\Sigma| = \begin{vmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{vmatrix} = |\Sigma_{11}| |\Sigma_{22}|, \quad \Sigma^{-1} = \begin{pmatrix} \Sigma_{11}^{-1} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22}^{-1} \end{pmatrix}.$$



Matriz de covarianza diagonal

Sigue que la parte relevante de $\ell(\boldsymbol{\theta})$ es dada por:

$$\begin{aligned}\ell(\boldsymbol{\theta}) = & -\frac{n}{2} \log |\boldsymbol{\Sigma}_{11}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}_1)^\top \boldsymbol{\Sigma}_{11}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_1) \\ & - \frac{n}{2} \log |\boldsymbol{\Sigma}_{22}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}_2)^\top \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_2)\end{aligned}$$

que puede ser escrita como:

$$\ell(\boldsymbol{\theta}) = \ell_1(\boldsymbol{\theta}_1) + \ell_2(\boldsymbol{\theta}_2),$$

con $\boldsymbol{\theta}_j = (\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_{jj})$, para $j = 1, 2$, y

$$\ell_j(\boldsymbol{\theta}_j) = -\frac{n}{2} \log |\boldsymbol{\Sigma}_{jj}| - \frac{1}{2} \text{tr } \boldsymbol{\Sigma}_{jj}^{-1} \mathbf{Q}_j(\boldsymbol{\mu}_j),$$

donde

$$\mathbf{Q}_j(\boldsymbol{\mu}_j) = \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}_j)(\mathbf{x}_i - \boldsymbol{\mu}_j)^\top.$$



Matriz de covarianza diagonal

De ahí que, usando el [Resultado 2](#) de la Sesión 6, obtenemos el estimador ML para Σ :

$$\hat{\Sigma} = \begin{pmatrix} \hat{\Sigma}_{11} & \mathbf{0} \\ \mathbf{0} & \hat{\Sigma}_{22} \end{pmatrix},$$

con

$$\hat{\Sigma}_{jj} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}_j)(\mathbf{x}_i - \bar{\mathbf{x}}_j)^\top,$$

para $j = 1, 2$, donde $\bar{\mathbf{x}} = (\bar{\mathbf{x}}_1^\top, \bar{\mathbf{x}}_2^\top)^\top$.



Muestras con parámetros ‘enlazados’

Suponga que la matriz de datos \mathbf{X} es particionada como:

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_k \end{pmatrix},$$

donde las filas de $\mathbf{X}_i \in \mathbb{R}^{n_i \times p}$ son IID $N_p(\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_{ii})$, para $i = 1, \dots, k$.

Las restricciones más comunes son:

(a) $\boldsymbol{\Sigma}_{11} = \dots = \boldsymbol{\Sigma}_{kk}$ (digamos, $= \boldsymbol{\Sigma}$).

(b) $\boldsymbol{\Sigma}_{11} = \dots = \boldsymbol{\Sigma}_{kk}$ y $\boldsymbol{\mu}_1 = \dots = \boldsymbol{\mu}_k$.



Muestras con parámetros ‘enlazados’

Para el caso en (a) note que podemos escribir:

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^k \ell_i(\boldsymbol{\theta}),$$

donde

$$\ell_i(\boldsymbol{\theta}) = -\frac{n_i}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \text{tr } \boldsymbol{\Sigma}^{-1} \{ \mathbf{Q}_i + n_i (\bar{\mathbf{x}}_i - \boldsymbol{\mu}_i)(\bar{\mathbf{x}}_i - \boldsymbol{\mu}_i)^\top \},$$

Sea

$$\mathbf{S}_i = \frac{1}{n_i} \mathbf{Q}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} (\mathbf{x}_j - \bar{\mathbf{x}}_i)(\mathbf{x}_j - \bar{\mathbf{x}}_i)^\top,$$

para $i = 1, \dots, k$. Es decir,

$$\ell(\boldsymbol{\theta}) = -\frac{1}{2} \sum_{i=1}^k \left\{ n_i \log |\boldsymbol{\Sigma}| + n_i \text{tr } \boldsymbol{\Sigma}^{-1} (\mathbf{S}_i + (\bar{\mathbf{x}}_i - \boldsymbol{\mu}_i)(\bar{\mathbf{x}}_i - \boldsymbol{\mu}_i)^\top) \right\}.$$



Muestras con parámetros ‘enlazados’

Como **no existe** restricciones sobre μ sigue que el MLE de μ es \bar{x}_i ($i = 1, \dots, k$). Además, considere

$$\mathbf{W} = \sum_{i=1}^k n_i \mathbf{S}_i, \quad n = \sum_{i=1}^k n_i.$$

De este modo, la **log-verosimilitud perfilada**, es dada por:

$$\ell_*(\Sigma) = \ell(\hat{\mu}, \Sigma) = -\frac{n}{2} \log |\Sigma| - \frac{1}{2} \text{tr } \Sigma^{-1} \mathbf{W}.$$

De ahí que el MLE para Σ adopta la forma:²

$$\hat{\Sigma} = \frac{1}{n} \mathbf{W} = \frac{1}{n} \sum_{i=1}^k n_i \mathbf{S}_i$$

El caso en (b) es análogo (se deja como Ejercicio).

²Es decir $\hat{\Sigma}_{ii} = \hat{\Sigma}$, para $i = 1, \dots, k$.

