

MAT-269: Conceptos preliminares

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Esperanza y covarianza

Sea \mathbf{x} vector aleatorio n -dimensional con densidad f . Entonces la **esperanza** de cualquier función \mathbf{g} (de \mathbf{x}) es dada por:

$$E(\mathbf{g}(\mathbf{x})) = \int_{\mathbb{R}^n} \mathbf{g}(\mathbf{t}) f(\mathbf{t}) d\mathbf{t},$$

siempre que la integral (n -dimensional) exista.

Considere $\mathbf{Z} = (z_{ij})$ una función matricial $m \times n$, entonces podemos definir la esperanza de una **matriz aleatoria** como:

$$E(\mathbf{Z}(\mathbf{x})) = (E(z_{ij})), \quad z_{ij} = z_{ij}(\mathbf{x}).$$

Evidentemente

$$E(\mathbf{A}) = \mathbf{A},$$

para $\mathbf{A} = (a_{ij})$ matriz de constantes.



Resultado 1:

Sea $A = (a_{ij})$, $B = (b_{ij})$ y $C = (c_{ij})$ matrices de constantes $l \times m$, $n \times p$ y $l \times p$, respectivamente. Entonces

$$E(ABZ + C) = AE(Z)B + C.$$

Demostración:

Sea $Y = ABZ + C$, entonces

$$y_{ij} = \sum_{r=1}^m \sum_{s=1}^n a_{ir} z_{rs} b_{sj} + c_{ij},$$

de este modo

$$\begin{aligned} E(ABZ + C) &= (E(y_{ij})) = \left(\sum_{r=1}^m \sum_{s=1}^n a_{ir} E(z_{rs}) b_{sj} + c_{ij} \right) \\ &= AE(Z)B + C. \end{aligned}$$



Definición 1:

Sean \mathbf{x} e \mathbf{y} vectores aleatorios m y n -dimensionales, respectivamente. Se define la **matriz de covarianza** entre \mathbf{x} e \mathbf{y} como la matriz $m \times n$,

$$\text{Cov}(\mathbf{x}, \mathbf{y}) = (\text{Cov}(x_i, y_j)).$$

Observación:

Es fácil notar que:

$$\begin{aligned}\text{Cov}(\mathbf{x}, \mathbf{y}) &= E\{(\mathbf{x} - E(\mathbf{x}))(\mathbf{y} - E(\mathbf{y}))^T\} \\ &= E(\mathbf{x}\mathbf{y}^T) - E(\mathbf{x}) E^T(\mathbf{y}).\end{aligned}$$

Adicionalmente,

$$\text{Cov}(\mathbf{x}) = \text{Cov}(\mathbf{x}, \mathbf{x}) = E(\mathbf{x}\mathbf{x}^T) - E(\mathbf{x}) E^T(\mathbf{x}),$$

es llamada **matriz de dispersión**.



Resultado 2:

Si \mathbf{x} e \mathbf{y} son vectores aleatorios m y n -dimensionales, respectivamente y $\mathbf{A} \in \mathbb{R}^{l \times m}$, $\mathbf{B} \in \mathbb{R}^{p \times n}$, entonces

$$\text{Cov}(\mathbf{Ax}, \mathbf{By}) = \mathbf{A} \text{Cov}(\mathbf{x}, \mathbf{y}) \mathbf{B}^\top.$$

Observación:

Tenemos el siguiente caso particular,

$$\text{Cov}(\mathbf{Ax}) = \text{Cov}(\mathbf{Ax}, \mathbf{Ax}) = \mathbf{A} \text{Cov}(\mathbf{x}, \mathbf{x}) \mathbf{A}^\top = \mathbf{A} \text{Cov}(\mathbf{x}) \mathbf{A}^\top.$$



Resultado 3:

Toda matriz de dispersión es simétrica y semidefinida positiva.

Demostración:

La simetría de la matriz de dispersión es obvia. Sea $\mathbf{z} = \mathbf{x} - E(\mathbf{x})$, y considere la variable aleatoria $y = \mathbf{a}^\top \mathbf{z}$, para $\mathbf{a} \in \mathbb{R}^n$ un vector arbitrario. Entonces,

$$\begin{aligned}\mathbf{a}^\top \text{Cov}(\mathbf{x}) \mathbf{a} &= \mathbf{a}^\top E(\mathbf{x} - E(\mathbf{x}))(\mathbf{x} - E(\mathbf{x}))^\top \mathbf{a} \\ &= E(\mathbf{a}^\top (\mathbf{x} - E(\mathbf{x}))(\mathbf{x} - E(\mathbf{x}))^\top \mathbf{a}) \\ &= E(\mathbf{a}^\top \mathbf{z} \mathbf{z}^\top \mathbf{a}) = E(y^2) \geq 0\end{aligned}$$

y por tanto, $\text{Cov}(\mathbf{x})$ es semidefinida positiva.



Suponga que $\text{Cov}(\mathbf{x})$ es semidefinida positiva de rango r ($r \leq n$). Luego

$$\text{Cov}(\mathbf{x}) = \mathbf{B}\mathbf{B}^\top,$$

donde $\mathbf{B} \in \mathbb{R}^{n \times r}$ de rango r .

Sea \mathbf{y} vector aleatorio r -dimensional con $E(\mathbf{y}) = \mathbf{0}$ y $\text{Cov}(\mathbf{y}) = \mathbf{I}$. Haciendo $\mathbf{x} = \mathbf{B}\mathbf{y}$, sigue que $E(\mathbf{x}) = \mathbf{0}$ y

$$\text{Cov}(\mathbf{x}) = \text{Cov}(\mathbf{B}\mathbf{y}) = \mathbf{B} \text{Cov}(\mathbf{y}) \mathbf{B}^\top = \mathbf{B}\mathbf{B}^\top.$$

Es decir, corresponde a una matriz de covarianza.



Resultado 4:

Sea \mathbf{x} vector aleatorio n -dimensional y considere la **transformación lineal**

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b},$$

donde \mathbf{A} es una matriz de constantes $m \times n$ y \mathbf{b} es vector de constantes $m \times 1$.
Entonces

$$\mathbf{E}(\mathbf{y}) = \mathbf{A} \mathbf{E}(\mathbf{x}) + \mathbf{b}, \quad \text{Cov}(\mathbf{y}) = \mathbf{A} \text{Cov}(\mathbf{x}) \mathbf{A}^{\top}.$$



Ejemplo (estandarización):

Sea \mathbf{x} vector aleatorio n -dimensional con media $E(\mathbf{x}) = \boldsymbol{\mu}$ y matriz de dispersión $\text{Cov}(\mathbf{x}) = \boldsymbol{\Sigma}$, tal que podemos escribir

$$\boldsymbol{\Sigma} = \mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^\top$$

donde \mathbf{U} es matriz ortogonal y $\boldsymbol{\Lambda} = \text{diag}(\boldsymbol{\lambda})$. Considere,

$$\mathbf{z} = \boldsymbol{\Lambda}^{-1/2}\mathbf{U}^\top(\mathbf{x} - \boldsymbol{\mu})$$

de este modo, obtenemos que

$$E(\mathbf{z}) = \mathbf{0} \quad \text{y} \quad \text{Cov}(\mathbf{z}) = \mathbf{I}.$$



Ejemplo (Whitening):

Para $\mathbf{x} = (x_1, x_2, \dots, x_p)^\top$ con $E(\mathbf{x}) = \boldsymbol{\mu}$ y $\text{Cov}(\mathbf{x}) = \boldsymbol{\Sigma}$. La transformación,

$$\mathbf{z} = \mathbf{W}\mathbf{x},$$

tal que $\text{Cov}(\mathbf{z}) = \mathbf{I}$ es conocida como *whitening*.

Evidentemente, debemos tener que

$$\text{Cov}(\mathbf{z}) = \mathbf{W} \text{Cov}(\mathbf{x}) \mathbf{W}^\top = \mathbf{W} \boldsymbol{\Sigma} \mathbf{W}^\top = \mathbf{I},$$

es decir,

$$\mathbf{W}(\boldsymbol{\Sigma} \mathbf{W}^\top \mathbf{W}) = \mathbf{W}, \quad \implies \quad \mathbf{W}^\top \mathbf{W} = \boldsymbol{\Sigma}^{-1}.$$



Observación:

Existen varios métodos tradicionales para obtener \mathbf{W} (Kessy et al., 2018)¹. Por ejemplo:

- ▶ **PCA whitening**: basado en $\mathbf{\Sigma} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top$, obtenemos

$$\mathbf{W}_{\text{PCA}} = \mathbf{\Lambda}^{-1/2}\mathbf{U}^\top.$$

- ▶ **Cholesky whitening**: considere $\mathbf{\Sigma}^{-1} = \mathbf{L}\mathbf{L}^\top$, donde \mathbf{L} es triangular inferior. Entonces,

$$\mathbf{W}_{\text{Chol}} = \mathbf{L}^\top.$$

¹The American Statistician **72**, 309-314.



Definición 2:

Sea $\mathbf{x} = (x_1, \dots, x_p)^\top$ vector aleatorio con media $\boldsymbol{\mu}$ y matriz de covarianza $\boldsymbol{\Sigma}$. Se define la matriz de correlación como $\mathbf{R} = (\rho_{ij})$, donde

$$\rho_{ij} = \frac{\text{Cov}(x_i, x_j)}{\{\text{var}(x_i) \text{var}(x_j)\}^{1/2}} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii} \sigma_{jj}}}, \quad i, j = 1, \dots, p.$$

Observación:

Considere $\mathbf{D} = \text{diag}(\sigma_{11}, \dots, \sigma_{pp}) = \text{diag}(\boldsymbol{\Sigma})$, entonces podemos escribir

$$\mathbf{R} = \mathbf{D}^{-1/2} \boldsymbol{\Sigma} \mathbf{D}^{-1/2}.$$

(y análogamente $\boldsymbol{\Sigma} = \mathbf{D}^{1/2} \mathbf{R} \mathbf{D}^{1/2}$).



Definición 3:

Si el vector aleatorio \mathbf{x} tiene **función característica** dada por

$$\varphi(\mathbf{t}) = \exp\left(i\mathbf{t}^\top \boldsymbol{\mu} - \frac{1}{2}\mathbf{t}^\top \boldsymbol{\Sigma} \mathbf{t}\right),$$

decimos que sigue una **distribución normal multivariada** y anotamos $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$

Resultado 5:

Suponga que $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y considere la **transformación** $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$ donde $\mathbf{A} \in \mathbb{R}^{m \times p}$ con $\text{rk}(\mathbf{A}) = m$ y $\mathbf{b} \in \mathbb{R}^m$. Entonces

$$\mathbf{y} \sim N_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top).$$



Resultado 6:

Si $\mathbf{z} \sim N_p(\mathbf{0}, \mathbf{I})$. Entonces

$$E(\mathbf{z}) = \mathbf{0}, \quad \text{Cov}(\mathbf{z}) = \mathbf{I}.$$

Observación:

Sea

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{B}\mathbf{z}, \quad \mathbf{z} \sim N_p(\mathbf{0}, \mathbf{I}),$$

donde $\boldsymbol{\Sigma} = \mathbf{B}\mathbf{B}^\top$ con \mathbf{B} matriz de rango completo. Por el [Resultado 5](#), sigue que

$$\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \quad \boldsymbol{\Sigma} \geq \mathbf{0}.$$

Además,

$$E(\mathbf{x}) = \boldsymbol{\mu} + \mathbf{B} E(\mathbf{z}) = \boldsymbol{\mu}$$

$$\text{Cov}(\mathbf{x}) = \text{Cov}(\boldsymbol{\mu} + \mathbf{B}\mathbf{z}) = \mathbf{B} \text{Cov}(\mathbf{z}) \mathbf{B}^\top = \boldsymbol{\Sigma}.$$



Considere la siguiente partición:

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}, \quad (1)$$

donde x_1 y μ_1 son vectores $k \times 1$ y Σ_{11} es $k \times k$.

Resultado 7:

Si $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, entonces la distribución marginal de cualquier subconjunto de k ($< p$) componentes de \mathbf{x} es normal k -variada.

Resultado 8:

Si $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y \mathbf{x} , $\boldsymbol{\mu}$ y $\boldsymbol{\Sigma}$ son particionadas como en la Ecuación (1). Entonces los vectores x_1 y x_2 son independientes sólo si $\Sigma_{12} = 0$.



Resultado 9:

Si $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y $\boldsymbol{\Sigma}$ es definida positiva, entonces la **densidad** de \mathbf{x} asume la forma

$$f(\mathbf{x}) = |\mathbf{2}\pi\boldsymbol{\Sigma}|^{-1/2} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}, \quad \mathbf{x} \in \mathbb{R}^p.$$

Ejemplo:

Sea $\mathbf{x} \sim N_2(\mathbf{0}, \boldsymbol{\Sigma})$ donde

$$\boldsymbol{\Sigma} = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}, \quad -1 < \rho < 1.$$


En cuyo caso, la función de densidad es dada por:

$$f(\mathbf{x}) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}(x_1^2 + x_2^2 - 2\rho x_1 x_2)\right\}.$$


A continuación se presenta la función de densidad para los casos $\rho = 0.0, 0.4$ y 0.8 .




Distribución normal multivariada




(a) $\rho = 0.0$




(b) $\rho = 0.4$




(c) $\rho = 0.8$



(d) contornos



(e) contornos



(f) contornos

Observación:

Es fácil notar que la función de densidad es constante sobre el elipsoide

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = \lambda,$$

en \mathbb{R}^p para todo $\lambda > 0$. Este elipsoide tiene centro $\boldsymbol{\mu}$, mientras que $\boldsymbol{\Sigma}$ determina su forma y orientación. Además, la variable aleatoria

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = \mathbf{z}^\top \mathbf{z} = \sum_{i=1}^p z_i^2,$$

sigue una distribución **chi-cuadrado** con p grados de libertad y la cantidad

$$D = \{(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\}^{1/2},$$

se conoce como **distancia de Mahalanobis**² de \mathbf{x} a $\boldsymbol{\mu}$.

²En ocasiones, decimos que $D^2 = (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})$ es la 'distancia' de Mahalanobis.

Resultado 10:

Sea $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y particione \mathbf{x} , $\boldsymbol{\mu}$ y $\boldsymbol{\Sigma}$ como:

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix},$$

donde \mathbf{x}_1 y $\boldsymbol{\mu}_1$ son vectores $k \times 1$, mientras que $\boldsymbol{\Sigma}_{11}$ es matriz $k \times k$. Sea $\boldsymbol{\Sigma}_{22}^-$ una inversa generalizada de $\boldsymbol{\Sigma}_{22}$, esto es, una matriz que satisface

$$\boldsymbol{\Sigma}_{22} \boldsymbol{\Sigma}_{22}^- \boldsymbol{\Sigma}_{22} = \boldsymbol{\Sigma}_{22},$$

y sea $\boldsymbol{\Sigma}_{11 \cdot 2} = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^- \boldsymbol{\Sigma}_{21}$. Entonces

(a) $\mathbf{x}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^- \mathbf{x}_2 \sim N_k(\boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^- \boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{11 \cdot 2})$ y es independiente de \mathbf{x}_2 .

(b) La **distribución condicional**

$$(\mathbf{x}_1 | \mathbf{x}_2 = \mathbf{u}) \sim N_k(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^- (\mathbf{u} - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11 \cdot 2}).$$

